

MS 16/10/24

SOLGIMENTO DI ESERCIZI

1. Supponiamo per semplicità che i 40 geni di un genoma possano essere divisi in tre classi disgiunte: classe A di numerosità 20, B e C di numerosità 10 ciascuna. Le tre classi possono per esempio rappresentare funzioni biologiche distinte, o avere origini genetiche diverse.

(a) si calcoli la probabilità di osservare nessun gene di classe A, due di classe B e tre di classe C in una estrazione casuale di 5 geni;

$$P(N_A=0, N_B=2, N_C=3) = \frac{\binom{20}{0} \binom{10}{2} \binom{10}{3}}{\binom{40}{5}} = \dots = \text{dmvhyper}(c(0,2,3), c(20,10,10), 5) = 0.008206587$$

dal testo, si evince
senza
reintrodurre
→ hyper. mult)

library extraDistr

(b) come approssimazione, si calcoli la stessa probabilità nel caso di campionamento casuale con reintroduzione; (→ multinomial)

$$\frac{5!}{0! 2! 3!} \left(\frac{20}{40}\right)^0 \left(\frac{10}{40}\right)^2 \left(\frac{10}{40}\right)^3 = \frac{10}{4^5} = \text{dmnom}(c(0,2,3), 5, c(1/2, 1/4, 1/4)) = 0.009765625$$

(c) si calcolino la probabilità di osservare qualunque campione così estremo o più estremo del precedente rispetto all'ipotesi di campionamento casuale (senza reintroduzione).


Si noti che la seconda domanda equivale al calcolo del *p-value* per una generalizzazione multivariata di quello che si chiama *test esatto di Fisher* dell'ipotesi nulla di campionamento casuale; a ben guardare, i campioni più estremi sono semplicemente quelli che hanno probabilità più piccole sotto campionamento casuale. Come supporto di calcolo si può usare la libreria `extraDistr` di R, usata anche nella soluzione del primo punto. Si veda infine

<https://www.youtube.com/watch?v=EF94wPaqXM0>

per una illustrazione del test di Fisher univariato (una classe per volta) alla *Gene Set Analysis*.


$n=2$

(a) Trovare la distribuzione di: $\begin{pmatrix} X \\ Y \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1/3 \end{pmatrix} \begin{pmatrix} Z_1 \\ Z_2 \end{pmatrix}$ ~~$+ \begin{pmatrix} 0 \\ 0 \end{pmatrix}$~~



$$\Sigma = AA' = \begin{pmatrix} 1 & 0 \\ 0 & 1/3 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1/3 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1/9 \end{pmatrix}$$

$$\rho(x, y) = \frac{1}{\sqrt{1 \cdot \frac{1}{9}}} = 0$$



(c) Trovare la distribuzione di: $\begin{pmatrix} X \\ Y \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 1 & 1/3 \end{pmatrix} \begin{pmatrix} Z_1 \\ Z_2 \end{pmatrix}$

e scrivere $P(Y < 3X + 1)$ come integrale doppio.

$$\Sigma = \text{Var} \text{ Cov} \begin{pmatrix} X \\ Y \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 1 & 1/3 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1/3 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 1 & 1/10 \end{pmatrix}$$

$$\text{Var}(X) = \text{Var}(Z_1) = 1$$

$$\text{Var}(Y) = \text{Var}(Z_1 + Z_2/3) = \frac{10}{9}$$

$$\text{Cov}(X, Y) = 1$$

$$\rho = \frac{1}{\sqrt{1 \cdot \frac{10}{9}}} = \frac{3}{\sqrt{10}} \approx .95$$




trovare la distribuzione di $Y|X = x$.

$$Y|X=x \sim N\left(\mu_Y + \rho \frac{\sigma_Y}{\sigma_X}(x - \mu_X), (1 - \rho^2)\sigma_Y^2\right)$$

$$= N\left(x, \frac{1}{9}\right)$$

$$P(Y < 3X + 1) = \int_{-\infty}^{+\infty} \int_{-\infty}^{3x+1} \frac{1}{2\pi} \left(\frac{(1 - \frac{9}{10}) \frac{10}{9}}{9} \right)^{-\frac{1}{2}} \times$$





$$\times \exp \left\{ -\frac{1}{2(1 - \frac{9}{10})} \left[x^2 - 2 \frac{3}{\sqrt{10}} x \frac{y}{\sqrt{\frac{10}{9}}} + \frac{y^2}{\frac{10}{9}} \right] \right\} dy dx$$

= ... un po' di

Analisi Numerica
oppure Monte Carlo

(b) Trovare la distribuzione di: $\begin{pmatrix} X \\ Y \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 1/3 & 0 \end{pmatrix} \begin{pmatrix} Z_1 \\ Z_2 \end{pmatrix}$
e calcolare $P(Y < 3X + 1)$.



$$P(Y < 3X + 1)$$

$$= P(X > -\frac{3}{8})$$

$$= 1 - P(Z < -\frac{3}{8})$$

$$= P(Z > \frac{3}{8}) \approx 0.6462$$

$\begin{pmatrix} X \\ Y \end{pmatrix}$ non ha densità
rispetto alla misura
di Lebesgue in \mathbb{R}^2
perché vive su una
retta (che ha
dimensione 1)

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim N_2 \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & 0 \\ 1/3 & 0 \end{pmatrix} \begin{pmatrix} 1 & 1/3 \\ 0 & 0 \end{pmatrix} \right)$$

3. Siano Z_1, Z_2, \dots, Z_3 i.i.d. normali standard e

$$\begin{pmatrix} X \\ Y \\ S \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} Z_1 \\ Z_2 \\ Z_3 \end{pmatrix} + \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}$$

- (a) Calcolare media e matrice di varianze e covarianze di $(X, Y, S)'$.
 (b) Scrivere $P(X < 0 \cap S < 0)$ come integrale doppio.
 (c) Trovare la distribuzione condizionata di S dato $X = x \cap Y = y$.

(a) $E \begin{pmatrix} X \\ Y \\ S \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}$

$Var Cov \begin{pmatrix} X \\ Y \\ S \end{pmatrix} = A A' = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 4 & 2 \\ 1 & 2 & 3 \end{pmatrix}$

(b) $\begin{pmatrix} X \\ S \end{pmatrix} \sim N_2 \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & 1 \\ 1 & 3 \end{pmatrix} \right)$

Stessa cosa di 2 cc,

$P(X < 0 \cap S < 0) = \int_{-\infty}^0 \int_{-\infty}^0 f_{(X,S)}(x,s) dx ds$

(c) applico la formula p.s. generale
che coinvolge
otteniamo
 $\Sigma_{11}^{-1} = \begin{pmatrix} 1 & 0 \\ 0 & 1/4 \end{pmatrix} \mid X=x, Y=y \sim N(x + \frac{y}{2} - \frac{1}{2}, 1)$