

Homework2 Rostagno File2

295706

January 11, 2025

Esercizio 1

- **Punto 1:** Come prima cosa genero tramite `runif()` le due coordinate per ogni punto s e le salvo in una matrice.
Mostro tramite plot grafico i 100 punti ottenuti




Figure 1: Osservazioni effettuate

Successivamente calcolo la matrice di covarianza applicando la formula data nel modello e calcolando le distanza come una matrice dove in ogni posizione é indicata la distanza tra il punto s_i e il punto s_j .
Ora posso campionare W come campione di una normale multi variata tramite il comando `mvrnorm()`.

Infine trattandosi di un processo gaussiano possiamo scrivere Y come:

$$Y(s) = W(s) + \epsilon_i$$

Dove $\epsilon \sim \mathcal{N}(0, \tau^2)$ e quindi campionarlo.

- **Punto 2:** Calcolo i quartili e li salvo in un vettore tramite il comando `quantile()`.

Successivamente creo un vettore "colore" inizializzato con il rosso per ogni osservazione y . Ora verifico ogni osservazione a quale quartile appartiene e ne modifico il colore nel vettore "colore".

Infine eseguo uno scatterplot delle osservazioni e imposto la voce colore con il set creato precedentemente ottenendo dunque

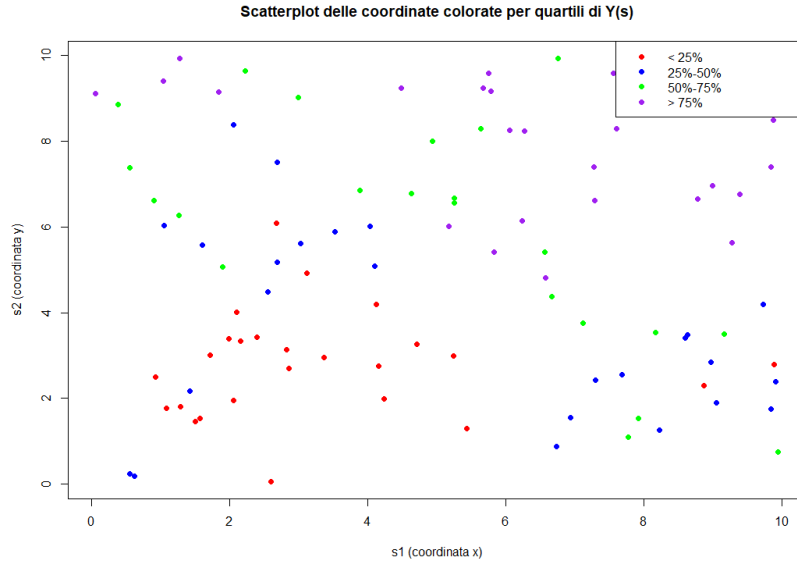


Figure 2: Quartili delle osservazioni

- **Punto 3:** Come numero casuale ho ottenuto il 66, successivamente ho generato un indice casuale per decidere quali osservazioni (Y_o), quali coordinate (D_o) e quali valori (W_o) mantenere per utilizzarli nel campionamento delle full-conditional.

Devo svolgere un algoritmo MCMC per ottenere campioni da

$$f(\beta_0, \beta_1, \tau^2, \sigma^2, \phi | y_0, w_0)$$

Ho iniziato impostando 5000 iterate per l'algoritmo di Gibbs e iniziando i vari parametri secondo le indicazioni fornite nell'homework.

Come prior dei vari parametri ho utilizzato:

- $\beta_0 \sim N(0, 1000)$: in modo da non essere esplicativa
- $\beta_1 \sim N(0, 1000)$: in modo da non essere esplicativa
- $\tau^2 \sim \text{IG}(1, 1)$: inverted gamma
- $\sigma^2 \sim \text{IG}(1, 1)$: inverted gamma
- $\phi \sim U(\frac{3}{\max \text{ dist}}, \frac{3}{\min \text{ dist}})$: uniforme

Dove max dist e min dist sono i valori di distanza minima e massima tra le coordinate di D_o .

Successivamente ho creato dei vettori *samples_nome* per memorizzare i valori che verranno assunti dai parametri durante l'algoritmo.

Durante ogni iterata ho così deciso di campionare i vari parametri:

– **Campionamento di β_0**

Per trovare la full conditional di β_0 , ho considerato solo i termini di $f(\beta_0, \beta_1, \tau^2, \sigma^2, \phi, y_0, w_0)$ che dipendono da β_0 . Gli altri termini possono essere ignorati, poiché non influenzano il campionamento. Ottengo:

$$f(\beta_0 | \beta_1, \tau^2, \sigma^2, \phi, y_0, w_0) \sim f(\omega_o | \beta_0, \beta_1, \sigma^2, \phi) * f(\beta_0)$$

Dove la verosomiglianza é

$$f(w_0 | \beta_0, \beta_1, \phi) \propto |C|^{-\frac{1}{2}} \exp \left(-\frac{1}{2} (w_0 - m)^T C^{-1} (w_0 - m) \right),$$

Con $m = \beta_0 \mathbf{1} + \beta_1 \mathbf{s}_1$.

Mentre $\beta_0 \sim N(\mu_{\beta_0}, \tau_{\beta_0})$ in generale vale:

$$f(\beta_0) \propto \exp \left(-\frac{1}{2\tau_{\beta_0}^2} (\beta_0 - \mu_{\beta_0})^2 \right).$$

Combiniamole assieme eliminando i termini che non hanno dipendenza e otteniamo

$$f(\beta_0 | \dots) \propto \exp \left(-\frac{1}{2} \left[\beta_0^2 \left(\mathbf{1}^T C^{-1} \mathbf{1} + \frac{1}{\tau_{\beta_0}^2} \right) - 2\beta_0 \left(\mathbf{1}^T C^{-1} (\mathbf{w}_o - \beta_1 \mathbf{s}_1) + \frac{\mu_{\beta_0}}{\tau_{\beta_0}^2} \right) \right] \right).$$

Confrontiamo con la forma generale di una normale:

$$\exp \left(-\frac{1}{2} a \beta_0^2 + b \beta_0 \right) \sim \mathcal{N} \left(-\frac{b}{a}, \frac{1}{a} \right).$$

1. **Varianza della posteriori:**

$$\sigma_{\beta_0}^2 = \left(\mathbf{1}^T C^{-1} \mathbf{1} + \frac{1}{\tau_{\beta_0}^2} \right)^{-1}.$$

2. **Media della posteriori:**

$$\mu_{\beta_0} = -\sigma_{\beta_0}^2 \left(\mathbf{1}^T C^{-1} (\mathbf{w}_o - \beta_1 \mathbf{s}_1) + \frac{\mu_{\beta_0}}{\tau_{\beta_0}^2} \right).$$

– **Campionamento di β_1**

Per trovare la full conditional di β_1 , ho considerato solo i termini di $f(\beta_0, \beta_1, \tau^2, \sigma^2, \phi, y_0, w_0)$ che dipendono da β_1 . Gli altri termini possono essere ignorati, poiché non influenzano il campionamento. Ottengo:

$$f(\beta_1 | \beta_0, \tau^2, \sigma^2, \phi, y_0, w_0) \sim f(w_o | \beta_0, \beta_1, \sigma^2, \phi) * f(\beta_1)$$

Dove la verosomiglianza é

$$f(w_o | \beta_0, \beta_1, \phi) \propto |C|^{-\frac{1}{2}} \exp \left(-\frac{1}{2} (w_o - m)^T C^{-1} (w_o - m) \right),$$

Con $m = \beta_0 \mathbf{1} + \beta_1 \mathbf{s}_1$.

Mentre $\beta_1 \sim N(\mu_{\beta_1}, \tau_{\beta_1})$ in generale vale:

$$f(\beta_1) \propto \exp \left(-\frac{1}{2\tau_{\beta_1}^2} (\beta_1 - \mu_{\beta_1})^2 \right).$$

Combiniamole assieme eliminando i termini che non hanno dipendenza e otteniamo

$$\begin{aligned} f(\beta_1 | \beta_0, \mathbf{w}_o, \phi) &\propto \exp \left(-\frac{1}{2} [\beta_1^2 \mathbf{s}_1^T C^{-1} \mathbf{s}_1 - 2\beta_1 (\mathbf{s}_1^T C^{-1} \mathbf{w}_o - \beta_0 \mathbf{1}^T C^{-1} \mathbf{s}_1)] \right) \\ &\cdot \exp \left(-\frac{1}{2\tau_{\beta_1}^2} [\beta_1^2 - 2\mu_{\beta_1} \beta_1] \right). \end{aligned}$$

Confrontiamo con la forma generale di una normale:

$$\exp \left(-\frac{1}{2} a \beta_1^2 + b \beta_1 \right) \sim \mathcal{N} \left(-\frac{b}{a}, \frac{1}{a} \right).$$

1. Varianza della posteriori:

$$\sigma_{\beta_1}^2 = \left(\mathbf{s}_1^T C^{-1} \mathbf{s}_1 + \frac{1}{\tau_{\beta_1}^2} \right)^{-1}.$$

2. Media della posteriori:

$$\mu_{\beta_1} = -\sigma_{\beta_1}^2 \cdot \left(\mathbf{s}_1^T C^{-1} \mathbf{w}_o - \beta_0 \mathbf{1}^T C^{-1} \mathbf{s}_1 + \frac{\mu_{\beta_1}}{\tau_{\beta_1}^2} \right).$$

– **Campionamento di τ^2**

Per trovare la full conditional di τ^2 , ho considerato solo i termini di $f(\beta_0, \beta_1, \tau^2, \sigma^2, \phi, y_0, w_0)$ che dipendono da τ^2 . Gli altri termini possono essere ignorati, poiché non influenzano il campionamento. Ottengo:

$$f(\tau^2 | \beta_0, \beta_1, \sigma^2, \phi, y_0, w_0) \sim f(y_0 | w_0, \tau^2) * f(\tau^2)$$

Dove la verosomiglianza é

$$f(\mathbf{y}_o | \mathbf{w}_o, \tau^2) \propto (\tau^2)^{-\frac{n}{2}} \exp \left(-\frac{1}{2\tau^2} (\mathbf{y}_o - \mathbf{w}_o)^T (\mathbf{y}_o - \mathbf{w}_o) \right).$$

Mentre $\tau^2 \sim IG(a_\tau, b_\tau)$

$$f(\tau^2) \propto (\tau^2)^{-(a_\tau+1)} \exp\left(-\frac{b_\tau}{\tau^2}\right)$$

Combiniamole assieme eliminando i termini che non hanno dipendenza e otteniamo

$$f(\tau^2 | \mathbf{w}_o, \mathbf{y}_o) \propto (\tau^2)^{-\frac{n}{2}} \exp \left(-\frac{1}{2\tau^2} (\mathbf{y}_o - \mathbf{w}_o)^T (\mathbf{y}_o - \mathbf{w}_o) \right) \cdot (\tau^2)^{-(a_\tau+1)} \exp \left(-\frac{b_\tau}{\tau^2} \right).$$

Quindi come posteriori avremo

$$\tau^2 | \dots \sim IG \left(a_\tau + \frac{n}{2}, b_\tau + \frac{1}{2} (\mathbf{y}_o - \mathbf{w}_o)^T (\mathbf{y}_o - \mathbf{w}_o) \right).$$

– **Campionamento di σ^2**

Per trovare la full conditional di σ^2 , ho considerato solo i termini di $f(\beta_0, \beta_1, \tau^2, \sigma^2, \phi, y_0, w_0)$ che dipendono da σ^2 . Gli altri termini possono essere ignorati, poiché non influenzano il campionamento. Ottengo:

$$f(\sigma^2 | \beta_0, \tau^2, \beta_1, \phi, y_0, w_0) \sim f(w_0 | \beta_0, \beta_1, \sigma^2, \phi) * f(\sigma^2)$$

Dove la verosomiglianza é

$$f(w_0 | \beta_0, \beta_1, \phi, \sigma^2) \propto |C|^{-\frac{1}{2}} \exp \left(-\frac{1}{2} (w_0 - m)^T C^{-1} (w_0 - m) \right),$$

Con $m = \beta_0 1 + \beta_1 s_1$.

Mentre $\sigma^2 \sim IG(a_\sigma, b_\sigma)$

$$f(\sigma^2) \propto (\sigma^2)^{-(a_\sigma+1)} \exp\left(-\frac{b_\sigma}{\sigma^2}\right)$$

Combiniamole assieme eliminando i termini che non hanno dipendenza e otteniamo

$$f(\sigma^2 | \dots) \propto (\sigma^2)^{-\frac{n}{2}} \exp \left(-\frac{1}{2\sigma^2} (\mathbf{w}_o - m)^T R^{-1} (\mathbf{w}_o - m) \right) \cdot (\sigma^2)^{-(a_\sigma+1)} \exp \left(-\frac{b_\sigma}{\sigma^2} \right).$$

Con $m = \beta_0 1 + \beta_1 s_1$

e $R = \exp(-\phi * \text{distances})$.

Quindi come posteriori avremo

$$\sigma^2 | \dots \sim IG \left(a_\sigma + \frac{n}{2}, b_\sigma + \frac{1}{2} (\mathbf{w}_o - m)^T R^{-1} (\mathbf{w}_o - m) \right).$$

– **Campionamento di ϕ**

Per trovare la full conditional di ϕ , ho considerato solo i termini di $f(\beta_0, \beta_1, \tau^2, \sigma^2, \phi, y_0, w_0)$ che dipendono da ϕ . Gli altri termini possono essere ignorati, poiché non influenzano il campionamento. Ottengo:

$$f(\beta_1 | \beta_0, \tau^2, \sigma^2, \phi, y_0, w_0) \sim f(w_0 | \beta_0, \beta_1, \sigma^2, \phi) * f(\phi)$$

Dove la verosomiglianza é

$$f(w_0 | \beta_0, \beta_1, \phi) \propto |C|^{-\frac{1}{2}} \exp \left(-\frac{1}{2} (w_0 - m)^T C^{-1} (w_0 - m) \right)$$

Con $m = \beta_0 1 + \beta_1 s_1$.
Mentre $\phi \sim U(a_\phi, b_\phi)$

$$f(\phi) \propto \frac{1}{b_\phi - a_\phi}$$

Combiniamole assieme eliminando i termini che non hanno dipendenza e otteniamo

$$f(\phi \mid \dots) \propto |C|^{-\frac{1}{2}} \exp \left(-\frac{1}{2} (w_0 - m)^T C^{-1} (w_0 - m) \right) \cdot \frac{1}{b_\phi - a_\phi}$$

Ma purtroppo non riusciamo a dedurre nessuna forma chiusa, quindi per campionare ϕ utilizzeremo Metropolis-Hasting.
Come distribuzione proposal per il parametro ϕ^* proposto utilizzo

$$\phi^* \sim N(\phi, \eta)$$

Quindi centrata nel valore corrente di ϕ e come varianza inizializzata a 1.

Successivamente la varianza verrà modificata ogni 50 iterazioni secondo la formula

$$\eta_{new} = \exp(\log(\eta) + \frac{100}{200 + t} * (mean_alpha - 0.25))$$

Dove mean.alpha é la media dei 50 coefficienti alpha di accettazione.
Ora proponiamo un nuovo valore ϕ^* il quale deve appartenere al dominio $\phi \in [\frac{3}{\max \text{ dist}}, \frac{3}{\min \text{ dist}}]$ mostrato precedentemente e calcoliamo il rapporto di accettazione α come:

$$\alpha = \min \left(1, \frac{f(\phi^* \mid \dots) q(\phi \mid \phi^*)}{f(\phi \mid \dots) q(\phi^* \mid \phi)} \right),$$

dove:

- * $f(\phi^* \mid \dots)$: La full conditional di ϕ^* ,
- * $f(\phi \mid \dots)$: La full conditional di ϕ ,
- * $q(\phi^* \mid \phi)$: La distribuzione di proposta.

Siccome la proposta $q(\phi^* \mid \phi)$ è simmetrica (ad esempio, una normale centrata su ϕ), il rapporto di proposta si cancella:

$$\frac{q(\phi \mid \phi^*)}{q(\phi^* \mid \phi)} = 1.$$

Abbiamo che:

$$f(\phi^* | \dots) \propto |C(\phi^*)|^{-\frac{1}{2}} \exp \left(-\frac{1}{2}(W - \mu)^T C(\phi^*)^{-1}(W - \mu) \right),$$

$$f(\phi | \dots) \propto |C(\phi)|^{-\frac{1}{2}} \exp \left(-\frac{1}{2}(W - \mu)^T C(\phi)^{-1}(W - \mu) \right).$$

Come da suggerimento calcoleremo questo valore come $\exp^{\log(\alpha)}$ quindi otteniamo che

$$\begin{aligned} \log(\alpha) = & -\frac{1}{2} [\log(|C(\phi^*)|) + (W - \mu)^T C(\phi^*)^{-1}(W - \mu)] \\ & + \frac{1}{2} [\log(|C(\phi)|) + (W - \mu)^T C(\phi)^{-1}(W - \mu)]. \end{aligned}$$

Quindi possiamo proseguire in questa maniera per calcolare α cercando di evitare la cancellazione numerica

1. **Log-determinante:** Calcoliamo $\log(|C(\phi^*)|)$ e $\log(|C(\phi)|)$ usando la funzione determinante:

$$\text{log-det-term} = \frac{1}{2} [\log(|C(\phi)|) - \log(|C(\phi^*)|)].$$

2. **Termine quadratico:** Calcoliamo la differenza nei termini quadratici:

$$\text{quad-term} = \frac{1}{2} [(W - \mu)^T C(\phi^*)^{-1}(W - \mu) - (W - \mu)^T C(\phi)^{-1}(W - \mu)].$$

3. **Logaritmo di α :** Combiniamo i due termini:

$$\log(\alpha) = \text{log-det-term} + \text{quad-term}.$$

4. **Calcolo di α :** Passiamo dalla scala logaritmica a quella esponenziale:

$$\alpha = \min(1, \exp(\log(\alpha))).$$

Una volta ottenuto il valore α non ci resta che simulare $u \sim U(0, 1)$ e accettare α se $u \leq \alpha$ oppure in caso negativo mantenere lo stesso valore di ϕ .

Ora effettuo il burn-in di 1000 simulazioni per stabilizzare la convergenza.

Infine osservo tramite plot grafico l'evolversi dei parametri.

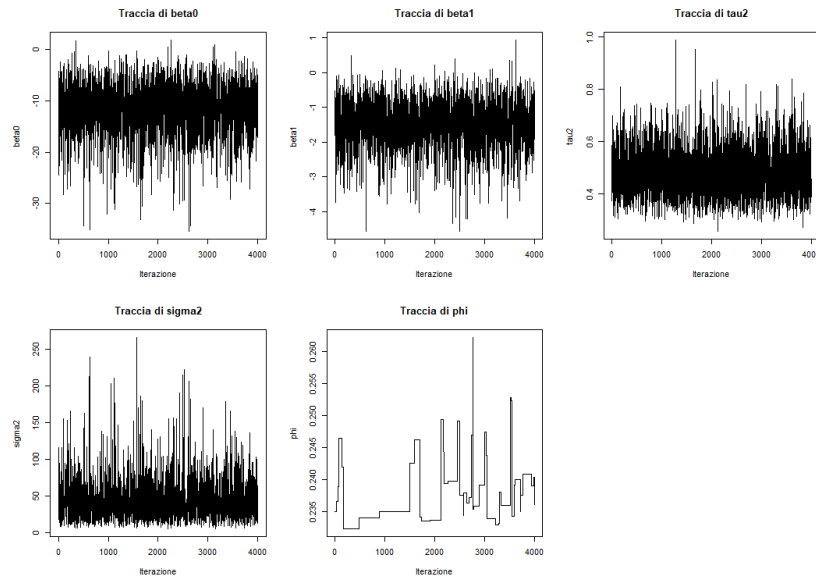


Figure 3: Evolversi del campionamento dei vari parametri

Esercizio 2

- Punto 1:** Come primo passo ho simulato il campione \mathbf{z} generando un vettore di lunghezza n dove in ogni sua posizione può contenere i valori 1, 2, 3 con probabilità π (ho utilizzato il comando `sample()`). Successivamente ho campionato le osservazioni y come campione di una Poisson di parametro $\lambda_1, \lambda_2, \lambda_3$ in base al valore corrispettivo di z_i (comando `rpois()`). Successivamente ho rappresentato tramite grafico le varie osservazioni ottenute divise per colore in base al parametro λ con cui sono state osservate. Sull'asse x sono presenti gli indici delle osservazioni (1:n) mentre sull'asse delle y sono presenti i valori assunti da ogni osservazione.

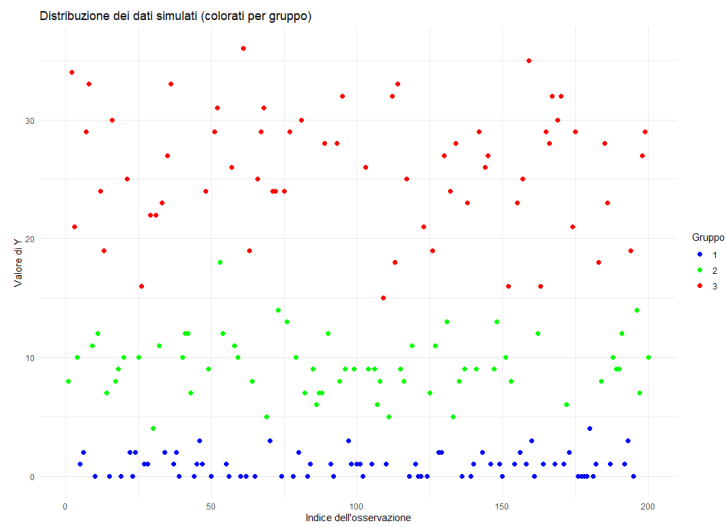


Figure 4: Osservazioni effettuate divise per gruppo

Successivamente ho rappresentato tramite istogramma il numero di osservazioni di ogni gruppo per osservare se il campionamento di \mathbf{z} ha rispettato le varie probabilità (ovviamente la somma delle tre colonne é n).




Figure 5: Numero di osservazioni di ogni gruppo

- **Punto 2:** Inizialmente ho assunto delle prior per i vari parametri in modo che fossero abbastanza neutrali (non devono dare troppa informazione a priori ai parametri):

- $\lambda_k \sim \text{Gamma}(1, 1)$: Parametro inizialmente non informativo.
- $\pi \sim \text{Dirichlet}(1, 1, 1)$: Distribuzione uniforme sui tre gruppi.

Successivamente ho creato delle matrici chiamate *samples_nome* per contenere i valori dei vari parametri durante le varie iterazioni dell'algoritmo MCMC.

Come algoritmo ho utilizzato il solito Gibbs sampler:

- Come prima cosa ho inizializzato i vari parametri tramite le prior sopra definite, mentre per z ho generato un vettore con `sample()` senza definire delle probabilità.
- Successivamente ho impostato un ciclo di 1000 iterate dove ad ogni iterata campionavo i parametri z, λ e π e salvavo i risultati nelle matrici.
- **Campionamento di z**
Per trovare la full conditional di z_i , ho considerato solo i termini di $f(y, z, \lambda, \pi)$ che dipendono da z_i . Gli altri termini possono essere ignorati, poiché non influenzano il campionamento. Ottengo:

$$f(z_i = k \mid y, \lambda, \pi) \propto f(z_i = k) \cdot P(y_i \mid \lambda_k) = \pi_k \cdot P(y_i \mid \lambda_k)$$

Espandendo i termini:

$$f(z_i = k \mid y, \lambda, \pi) \propto \pi_k \cdot \frac{\lambda_k^{y_i} e^{-\lambda_k}}{y_i!}$$

Dove:

- * π_k è la proporzione del gruppo k .
- * $P(y_i \mid \lambda_k) = \frac{\lambda_k^{y_i} e^{-\lambda_k}}{y_i!}$ è la probabilità di osservare y_i dato il parametro del gruppo k .

Poiché il termine $\frac{1}{y_i!}$ è costante rispetto a z_i , possiamo ignorarlo per il campionamento:

$$f(z_i = k \mid y, \lambda, \pi) \propto \pi_k \cdot \lambda_k^{y_i} e^{-\lambda_k}$$

Siccome il vettore π deve avere che la somma delle sue componenti sia uguale a 1, dobbiamo normalizzare il risultato in questo modo:

$$P(z_i = k \mid y, \lambda, \pi) = \frac{\pi_k \cdot \lambda_k^{y_i} e^{-\lambda_k}}{\sum_{j=1}^K \pi_j \cdot \lambda_j^{y_i} e^{-\lambda_j}}$$

Ora non mi resta che creare un ciclo for che per ogni osservazione y_i calcola questo vettore di probabilità (lunghezza 3 in questo caso, una per ogni λ) e genera sempre tramite `sample()` il valore z_i corrispondente.

Al termine del ciclo for avrò il mio campione di \mathbf{z} .

– Campionamento di lambda

Per trovare la full conditional di λ_k , considero solo i termini di $f(y, z, \lambda, \pi)$ che dipendono da λ_k :

$$f(\lambda_k \mid y, z, \pi) \propto f(\lambda_k) \cdot \prod_{i: z_i=k} P(y_i \mid \lambda_k).$$

La prior di λ_k è una distribuzione Gamma:

$$f(\lambda_k) \propto \lambda_k^{\alpha_k-1} e^{-\beta_k \lambda_k}.$$

La verosomiglianza per y_i nel gruppo k è Poisson:

$$P(y_i \mid \lambda_k) = \frac{\lambda_k^{y_i} e^{-\lambda_k}}{y_i!}.$$

Unendo prior e verosomiglianza:

$$f(\lambda_k \mid y, z, \pi) \propto \lambda_k^{\alpha_k-1} e^{-\beta_k \lambda_k} \cdot \prod_{i: z_i=k} \lambda_k^{y_i} e^{-\lambda_k}.$$

Espandendo i termini:

$$f(\lambda_k \mid y, z, \pi) \propto \lambda_k^{\alpha_k-1+\sum_{i: z_i=k} y_i} e^{-(\beta_k+n_k)\lambda_k}.$$

Dove:

$$n_k = \sum_{i: z_i=k} 1 \quad : \text{numero di osservazioni nel gruppo } k,$$

$$\sum_{i: z_i=k} y_i \quad : \text{somma delle osservazioni assegnate al gruppo } k.$$

La full conditional di λ_k è una distribuzione Gamma:

$$f(\lambda_k \mid y, z, \pi) \sim \text{Gamma} \left(\alpha_k + \sum_{i: z_i=k} y_i, \beta_k + n_k \right).$$

Ora non mi resta che impostare un ciclo for di lunghezza 3 e calcolare un campione con il comando `rgamma()` per ogni λ e salvarli tutti e 3 nella mia matrice.

– **Campionamento di π**

Per trovare la full conditional di π , considero solo i termini che dipendono da π :

$$f(\pi \mid y, z, \lambda) \propto f(\pi) \cdot \prod_{i=1}^n \prod_{k=1}^K \pi_k^{1_{z_i=k}}.$$

Espandendo:

* La prior di π è una Dirichlet:

$$f(\pi) \propto \prod_{k=1}^K \pi_k^{\alpha_k-1}.$$

* Il termine legato a z è:

$$\prod_{i=1}^n \prod_{k=1}^K \pi_k^{1_{z_i=k}} = \prod_{k=1}^K \pi_k^{n_k},$$

dove $n_k = \sum_{i=1}^n 1_{z_i=k}$ è il numero di osservazioni assegnate al gruppo k .

Combinando prior e verosomiglianza:

$$f(\pi \mid y, z, \lambda) \propto \prod_{k=1}^K \pi_k^{\alpha_k-1+n_k}.$$

La full conditional di π è una distribuzione Dirichlet:

$$f(\pi \mid y, z, \lambda) \sim \text{Dirichlet}(\alpha_1 + n_1, \alpha_2 + n_2, \dots, \alpha_K + n_K).$$

Adesso semplicemente campione un vettore di probabilità con il comando `rdichlet()`.

Ovviamente come campione di z utilizzo l'ultimo campione appreso e non quello iniziale (come viene indicato dall'algoritmo di Gibbs).

Una volta terminato l'algoritmo effettuo il burn-in dei primi 200 elementi poiché rovinano la convergenza.

Eseguo alcuni plot grafici ed osservo l'evolversi dei parametri λ e π

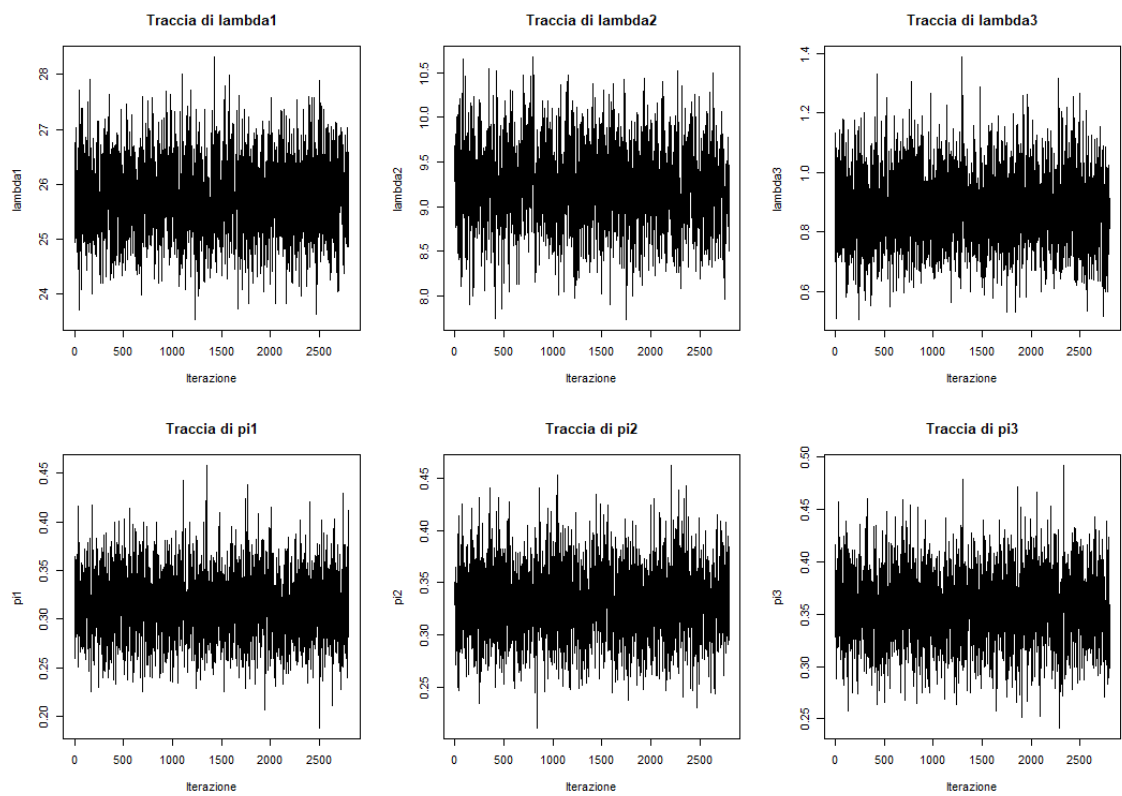


Figure 6: Osservazioni di ogni parametro