

# Time Series - Modelli

*Vers. 1.0.1*

Gianluca Mastrantonio

[gianluca.mastrantonio@polito.it](mailto:gianluca.mastrantonio@polito.it)

# Modello autoregressivo del primo ordine (AR(1)) I

## Modello Autoregressivo

Prima di passare al caso generale, vediamo il modello autoregressivo di ordine 1, che assume

$$x_t = \alpha x_{t-1} + w_t$$

dove come sempre  $w_t$  è un white noise. In questo caso la serie ha una lunghezza infinita. Ne deriva quindi che, sostituendo,

$$x_t = \alpha(\alpha x_{t-2} + w_{t-1}) + w_t = \alpha^2 x_{t-2} + \alpha w_{t-1} + w_t = \alpha^3 x_{t-3} + \alpha^2 w_{t-2} + \alpha w_{t-1} + w_t$$

e

$$x_t = \alpha^\infty x_{t-\infty} + \sum_{i=0}^{\infty} \alpha^i w_{t-i}$$

e assumeremo che  $|\alpha| < 1$  per far sì che la formula sopra (e altre caratteristiche del processo) abbia senso, e quindi

$$x_t = \sum_{i=0}^{\infty} \alpha^i w_{t-i}$$

## Modello autoregressivo del primo ordine (AR(1)) II

Visto che è combinazione lineare di processi Gaussiani è ancora Gaussiano e ne possiamo vedere media e varianza. Possiamo vedere facilmente che

$$E(X_t) = 0$$

mentre per covarianza al tempo  $t$  e  $t + k$  abbiamo

$$\begin{aligned}\gamma_t(k) &= Cov(X_t, X_{t+k}) = Cov\left(\sum_{i=0}^{\infty} \alpha^i W_{t-i}, \sum_{j=0}^{\infty} \alpha^j W_{t+k-j}\right) = \\ &= \sum_{i=0}^{\infty} \sum_{j=0}^{\infty} \alpha^i \alpha^j Cov(W_{t-i}, W_{t+k-j}) = \sum_{\substack{i=0 \\ j=k+i}}^{\infty} \alpha^i \alpha^{k+i} Cov(W_{t-i}, W_{t+k-(k+i)}) = \\ &= \sigma^2 \sum_{\substack{i=0 \\ j=k+i}}^{\infty} \alpha^i \alpha^{k+i}\end{aligned}$$

## Modello autoregressivo del primo ordine (AR(1)) III

de cui possiamo ricavare

$$\gamma_t(k) = \alpha^k \sigma^2 \sum_{i=0}^{\infty} \alpha^{2i}.$$

che ci da varianza

$$\gamma_t(0) = \sigma^2 \sum_{i=0}^{\infty} \alpha^{2i}.$$

Ricordiamo che la serie geometrica ci dice che

$$\frac{1}{1-\theta} = \sum_{i=0}^{\infty} \theta^i$$

se  $|\theta| < 1$ , altrimenti diverge. Quindi, visto che assumiamo che  $|\alpha| < 1$  la covarianza è non diverge e

$$\gamma_t(k) = \frac{\alpha^k \sigma^2}{(1 - \alpha^2)}$$

## Modello autoregressivo del primo ordine (AR(1)) IV

e la varianza

$$\gamma_t(0) = \frac{\sigma^2}{(1 - \alpha^2)}$$

altrimenti la varianza (e covarianza) diverge per  $|\alpha| \geq 1$ .

Questa è la ragione per cui in un random walk, che è un AR(1) con  $\alpha = 1$ , si assume noto il valore del primo tempo, altrimenti il processo diverge, e in più è non stazionario. Un white noise è invece stazionario visto che è un AR(1) con  $\alpha = 0$ .

La funzione di autocovarianza non dipende dal tempo, ma solo da lag, i.e.,  $\gamma_t(k) \equiv \gamma(k)$ , e la media è costantemente uguale a 0. Abbiamo allora che il processo è stazionario debole e anche forte (ricordatevi che per un processo gaussiano, se sono stazionari i momenti di ordine 1 e 2, è stazionario in maniera forte).

Calcoliamo i valori del correlogramma che è

$$\rho(k) = \frac{\gamma(k)}{\sqrt{\gamma(0)\gamma(0)}} = \frac{\alpha^k \sigma^2}{(1 - \alpha^2)} \frac{(1 - \alpha^2)}{\sigma^2} = \alpha^k$$

## Modello autoregressivo del primo ordine (AR(1)) V

Quindi, assumendo la stazionarietà, l'autocorrelazione decade con  $k$ , e se  $\alpha < 0$ , allora la correlazione alterna valori positivi e negativi. Vediamo degli esempi simulati. Fate attenzione che per simulare la congiunta possiamo usare la fattorizzazione

$$f(\mathbf{x}) = f(x_1) \prod_{i=2}^n f(x_i | x_{i-1})$$

dove  $x_1$  si deve simulare dalla marginale ( $N\left(0, \frac{\sigma^2}{(1-\alpha^2)}\right)$ ) e  $f(x_i | x_{i-1})$  della condizionata ( $N(\alpha x_{i-1}, \sigma^2)$ )

## Modello autoregressivo del primo ordine (AR(1)) VI




Figure: Simulazione di un AR(1) con  $\alpha = 0.3$

## Modello autoregressivo del primo ordine (AR(1)) VII

Code: Codice della figura

```
x = c()
alpha    = 0.3
sigma2    = 1.5
x[1] = rnorm(1,0,(sigma2/(1-alpha^2))^0.5)
for(i in 2:100)
{
  x[i] = rnorm(1,alpha*x[i-1],sigma2^0.5)
}
par(mfrow=c(1,3))
par("mar"=c(5, 5, 4, 2))
plot(x, type="l", main="sim", cex.main=3,
      cex.lab=3, cex.axis=3, xlab="Time", ylab="Sim")
acf(x, main="Acf", cex.main=3, cex.lab=3, cex.axis=3)
```



## Modello autoregressivo del primo ordine (AR(1)) VIII

```
pacf(x, main="p-Acf", cex.main=3, cex.lab=3, cex.axis=3)
```




Figure: Simulazione di un AR(1) con  $\alpha = 0.9$

## Modello autoregressivo del primo ordine (AR(1)) IX

Code: Codice della figura

```
x = c()
alpha    = 0.9
sigma2    = 1.5
x[1] = rnorm(1,0,(sigma2/(1-alpha^2))^0.5)
for(i in 2:100)
{
  x[i] = rnorm(1,alpha*x[i-1],sigma2^0.5)
}
par(mfrow=c(1,3))
par("mar"=c(5, 5, 4, 2))
plot(x, type="l", main="sim", cex.main=3,
      cex.lab=3, cex.axis=3, xlab="Time", ylab="Sim")
acf(x, main="Acf", cex.main=3, cex.lab=3, cex.axis=3)
```

## Modello autoregressivo del primo ordine (AR(1)) X

```
pacf(x, main="p-Acf", cex.main=3, cex.lab=3, cex.axis=3)
```




Figure: Simulazione di un AR(1) con  $\alpha = -0.3$

## Modello autoregressivo del primo ordine (AR(1)) XI

Code: Codice della figura

```
x = c()
alpha    = -0.3
sigma2    = 1.5
x[1] = rnorm(1,0,(sigma2/(1-alpha^2))^0.5)
for(i in 2:100)
{
  x[i] = rnorm(1,alpha*x[i-1],sigma2^0.5)
}
par(mfrow=c(1,3))
par("mar"=c(5, 5, 4, 2))
plot(x, type="l", main="sim", cex.main=3,
      cex.lab=3, cex.axis=3, xlab="Time", ylab="Sim")
acf(x, main="Acf", cex.main=3, cex.lab=3, cex.axis=3)
```

## Modello autoregressivo del primo ordine (AR(1)) XII

```
pacf(x, main="p-Acf", cex.main=3, cex.lab=3, cex.axis=3)
```




Figure: Simulazione di un AR(1) con  $\alpha = -0.9$

## Modello autoregressivo del primo ordine (AR(1)) XIII

Code: Codice della figura

```
x = c()
alpha    = -0.9
sigma2    = 1.5
x[1] = rnorm(1,0,(sigma2/(1-alpha^2))^0.5)
for(i in 2:100)
{
  x[i] = rnorm(1,alpha*x[i-1],sigma2^0.5)
}
par(mfrow=c(1,3))
par("mar"=c(5, 5, 4, 2))
plot(x, type="l", main="sim", cex.main=3,
      cex.lab=3, cex.axis=3, xlab="Time", ylab="Sim")
acf(x, main="Acf", cex.main=3, cex.lab=3, cex.axis=3)
```

## Modello autoregressivo del primo ordine (AR(1)) XIV

```
pacf(x, main="p-Acf", cex.main=3, cex.lab=3, cex.axis=3)
```

Fate attenzione che in questo caso è inutile calcolare l'autocorrelazione parziale, visto che è markoviano del primo ordine.

Possiamo passare dall AR(1) con media nulla, a uno con media  $\mu$  con i passaggi già fatti prima definendo

$$\mathbf{X} - \mu = N(\mathbf{0}, \Sigma),$$

con gli elementi di  $\Sigma$  dati dalla funzione di autocovarianza dell'AR(1), che ci da

$$(x_t - \mu) = \alpha(x_{t-1} - \mu) + w_t \Rightarrow x_t = \mu + \alpha(x_{t-1} - \mu) + w_t$$

# Modello autoregressivo di ordine $p$ (AR( $p$ )) I

## Modello autoregressivo di ordine $p$ (AR( $p$ ))

Passare da un modello AR(1) a un AR( $p$ ) è abbastanza semplice, e si può fare mettendo più “ritardi”

$$x_t = \alpha_1 x_{t-1} + \alpha_2 x_{t-2} + \cdots + \alpha_p x_{t-p} + w_t$$

Quindi il processo al tempo  $t$  dipende dai  $p$  tempi precedenti con differenti parametri (Markoviano di ordine  $p$ ).

Le proprietà del processo sono complesse da determinare. Per determinare se il processo è stazionario possiamo introdurre l'operatore  $B$  (backshift), per cui valgono le seguenti

$$Bx_t = x_{t-1}, \quad B^p x_t = x_{t-p}$$

che si può dimostrare essere un'operatore lineare che segue le usuali regole dell'algebra. Possiamo allora scrivere l'AR( $p$ ) come

$$x_t = (\alpha_1 B + \alpha_2 B^2 + \cdots + \alpha_p B^p)x_t + w_t \Rightarrow (1 - \alpha_1 B - \alpha_2 B^2 - \cdots - \alpha_p B^p)x_t = w_t$$



## Modello autoregressivo di ordine p (AR(p)) II

L'operatore ci servirà anche in futuro e definiamo

$$\theta_p(B) = (1 - \alpha_1 B - \alpha_2 B^2 - \dots - \alpha_p B^p)$$

come il polinomio backshift che ci permette di esprimere un AR(p) come

$$\theta_p(B)x_t = w_t$$

Per studiare le condizioni di stazionarietà possiamo esprimere l'equazione sopra come

$$x_t = \theta_p(B)^{-1} w_t$$

Il polinomio  $\theta_p(B)^{-1}$  ha una rappresentazione come serie

$$\theta_p(B)^{-1} = 1 + \sum_{i=1}^{\infty} c_i B^i$$

Modello autoregressivo di ordine  $p$  (AR( $p$ )) III

con ha la proprietà che  $c_i \Rightarrow 0$  se  $i \Rightarrow \infty$ , e la serie converge, se e solo se le radici del polinomio caratteristico di  $\theta_p(B)$ , i.e. le soluzioni di  $\theta_p(B) = 0$ , sono tutte maggiori di 1 in modulo.

**Attenzione:** Sono le radici del polinomio che devono essere in modulo maggiori di 1, non i coefficienti del modello. Cioè la richiesta è che le soluzioni di

$$1 - \alpha_1 B - \alpha_2 B^2 - \dots - \alpha_p B^p = 0$$

debbano essere maggiore di 1 in modulo. Prendiamo per esempio il caso AR(1), il cui polinomio è

$$1 - \alpha B = 0$$

che ha come soluzione

$$B = 1/\alpha$$

che quindi è stazionario se  $|1/\alpha| > 1$  che ci dà  $|\alpha| < 1$

## Modello autoregressivo di ordine p (AR(p)) IV

Calcoliamo adesso varianza/covarianza e valore atteso Visto che abbiamo che

$$Var(X_t) = (\theta_p(B)^{-1})^2 \sigma^2$$

questo ha varianza finita se e solo se  $\sum_{i=1} c_i B^i$  converge. L'equazione

$$x_t = \theta_p(B)^{-1} w_t$$

ci dice anche che

$$E(X_t) = 0$$

Vedremo in seguito come

$$x_t = \theta_p(B)^{-1} w_t$$

è la rappresentazione Moving Average di un modello Autoregressivo

## Modello autoregressivo di ordine $p$ (AR( $p$ )) V

Il calcolo dell'autocovarianza e autocorrelazione è complicato ma sappiamo che l'autocorrelazione parziale di un AR( $p$ ) si annulla per lag superiori a  $p$ . Questo ci può facilmente vedere calcolando la covarianza (e visto che è markoviano del  $p$ -esimo ordine)

$$Cov(x_t, x_{t-p-k} | x_{t_1}, \dots, x_{t_{t-p-k+1}}) =$$

$$\psi(p+k) = Cov(\alpha_1 x_{t-1} + \alpha_2 x_{t-2} + \dots + \alpha_p x_{t-p} + w_t, x_{t-p-k} | x_{t_1}, \dots, x_{t_{t-p-k+1}})$$

che per  $k > 0$  il primo argomento della covarianza non ha elementi in comune con  $x_{t-p+k}$ .

Per l'autocovarianza (e anche l'autocorrelazione) possiamo usare un calcolo iterativo visto se moltiplichiamo ambo i membri di

$$x_t = \alpha_1 x_{t-1} + \alpha_2 x_{t-2} + \dots + \alpha_p x_{t-p} + w_t$$

## Modello autoregressivo di ordine $p$ (AR( $p$ )) VI

per  $x_{t-k}$  e calcoliamo il valore atteso

$$E(X_{t-k}X_t) = \alpha_1 E(X_{t-k}X_{t-1}) + \alpha_2 E(X_{t-k}X_{t-2}) + \cdots + \alpha_p E(X_{t-k}X_{t-p}) + E(X_{t-k}w_t)$$

e ricordando che  $E(X_t) = 0$  per ogni  $t$ , allora

$$\gamma(k) = \alpha_1 \gamma(|k-1|) + \alpha_2 \gamma(|k-2|) + \cdots + \alpha_p \gamma(|k-p|)$$

Se fossimo in grado di calcolare le prime  $p$ , possiamo calcolare tutte le altre. Se non possiamo farlo potremmo sempre vederne e studiarne il comportamento con metodi MC

Come per l'AR(1) possiamo aggiungere un valore medio assumendo che  $\mathbf{X} - \mu$  sia un AR( $p$ ) e quindi

$$(x_t - \mu) = \alpha_1(x_{t-1} - \mu) + \alpha_2(x_{t-2} - \mu) + \cdots + \alpha_p(x_{t-p} - \mu) + w_t \Rightarrow$$

$$x_t = \mu + \alpha_1(x_{t-1} - \mu) + \alpha_2(x_{t-2} - \mu) + \cdots + \alpha_p(x_{t-p} - \mu) + w_t$$

## Modello autoregressivo di ordine p (AR(p)) VII




Figure: Simulazione di un AR(p) con  $\alpha_1 = 0.9$ ,  $\alpha_2 = -0.5$ ,  $\alpha_3 = 0.3$

## Modello autoregressivo di ordine p (AR(p)) VIII

Code: Codice della figura

```
x = c()
alpha1  = 0.7
alpha2  = -0.5
alpha3  = 0.3
sigma2  = 1.5
x[1] = 0
x[2] = 1
x[3] = 2
for(i in 4:500)
{
  x[i] = rnorm(1,alpha1*x[i-1]+
              alpha2*x[i-2]+alpha3*x[i-3],
              sigma2^0.5)
```

Modello autoregressivo di ordine  $p$  (AR( $p$ )) IX

```
}  
x = x[-c(1,400)]  
par(mfrow=c(1,3))  
par("mar"=c(5, 5, 4, 2))  
plot(x, type="l", main="sim", cex.main=3,  
      cex.lab=3, cex.axis=3, xlab="Time", ylab="Sim")  
acf(x, main="Acf", cex.main=3, cex.lab=3, cex.axis=3)  
pacf(x, main="p-Acf", cex.main=3, cex.lab=3, cex.axis=3)
```



# Modello autoregressivo di ordine $p$ (AR( $p$ )) X

## Previsione

In ambito di serie storiche, la previsione è un aspetto fondamentale. Ma la struttura gerarchica (definita come probabilità condizionate) di questi modelli ci permette di far previsione in maniera automatica, per esempio, nel modello AR( $p$ ), se abbiamo osservato il processo fino al tempo  $t$ , abbiamo che

$$x_{t+1} = \alpha_1 x_t + \alpha_2 x_{t-1} + \cdots + \alpha_p x_{t-p+1} + w_{t+1}$$

che è distribuita normalmente con media e varianza che si possono facilmente determinare. Abbiamo due casi, uno in cui le stime dei parametri sono considerate fisse, e in questo caso

$$x_{t+1} | x_t, \dots, x_{t-p+1}, \alpha_1, \dots, \alpha_p \sim N(\alpha_1 x_t + \alpha_2 x_{t-1} + \cdots + \alpha_p x_{t-p+1}, \sigma^2)$$

naturalmente con  $\alpha$ . e  $\sigma^2$  si intende la loro stima  $\hat{\alpha}$ . e  $\hat{\sigma}^2$ .

Modello autoregressivo di ordine  $p$  (AR( $p$ )) XI

L'altro caso è quello in cui i parametri  $\alpha$  e  $\sigma$  non sono considerati fissi e in questo caso va trovata la distribuzione di  $x_{t+1}$ , magari con metodi monte carlo se non si è in grado di trovarla, almeno approssimativamente. Generalmente si considerano fissi i parametri

Fate anche attenzione che se volete prevedere a una distanza  $c$  dovete prendere in considerazione che nel condizionante ci possono andare solo le osservazioni.

Prendiamo il caso di un AR(1):

$$x_t = \alpha x_{t-1} + w_t$$

La previsione al tempo  $t + 1$  è

$$x_{t+1} = \alpha x_t + w_{t+1} \sim N(\alpha x_t, \sigma^2)$$

se considero fissi i parametri, mentre la previsione al tempo  $t + 2$  è

$$x_{t+2} = \alpha x_{t+1} + w_{t+2} \sim N()$$

## Modello autoregressivo di ordine p (AR(p)) XII

dove i parametri della normale sono

$$E(x_{t+2}|x_t) = \alpha E(x_{t+1}|x_t) = \alpha^2 x_t$$

e

$$Var(x_{t+2}|x_t) = \alpha^2 Var(x_{t+1}|x_t) + Var(w_{t+2}) = \alpha^2 \sigma^2 + \sigma^2 = (1 + \alpha^2) \sigma^2$$

Lo stesso calcolo lo si può fare considerando

$$x_{t+2} = \alpha^2 x_t + \alpha w_{t+1} + w_{t+2}$$

oppure le medie e varianze condizionate della congiunta. Fate attenzione che in quest'ultimo caso ottenete

$$\sigma^2 \left( \frac{1}{1 - \alpha^2} - \frac{\alpha^{2k}}{1 - \alpha^2} \right)$$

che è lo stesso risultato ottenuto prima visto che

$$\frac{1}{1 - \alpha^2} - \frac{\alpha^4}{1 - \alpha^2} = \sum_{i=0}^{\infty} \alpha^{2i} - \sum_{i=0}^{\infty} \alpha^{4+2i} = 1 + \alpha^2$$

Modello autoregressivo di ordine  $p$  (AR( $p$ )) XIII

Si può continuare calcolando per lag superiori, e si può vedere

$$x_{t+k} = \alpha^k x_t + \sum_{i=0}^{k-1} \alpha^i w_{t+k-i}$$

e quindi

$$E(x_{t+k}|x_t) = \alpha^k x_t$$

e

$$Var(x_{t+k}|x_t) = (1 + \alpha^2 + \alpha^4 + \dots + \alpha^{2k})\sigma^2$$

e per  $k$  elevati la varianza tende alla varianza marginale  $\sigma^2/(1 - \alpha^2)$ .

Modello autoregressivo di ordine  $p$  (AR( $p$ )) XIV**Stima dei Parametri**

Prendiamo il caso generale in cui la distribuzione congiunta dei dati è una normale multivariata con media diversa da zero

$$\mathbf{X} \sim N(\mathbf{Z}\boldsymbol{\lambda}, \boldsymbol{\Sigma})$$

dove le  $\mathbf{Z}$  sono covariate,  $\boldsymbol{\lambda}$  sono coefficienti regressivi, e  $\boldsymbol{\Sigma}$  dipende da dei parametri  $\alpha$  e  $\sigma^2$  (potresti scrivere  $\boldsymbol{\Sigma}(\alpha, \sigma^2)$ ). Possiamo scrivere questo modello utilizzando il formalismo della regressione, nel seguente modo

$$x_i = \lambda_0 + \lambda_1 z_{i,1} + \cdots + \lambda_p z_{i,p} + \epsilon_i$$

con  $\boldsymbol{\epsilon} = (\epsilon_1, \dots, \epsilon_n)' \sim N(\mathbf{0}, \boldsymbol{\Sigma})$ .

la verosimiglianza del modello è

$$f(\mathbf{x}|\boldsymbol{\lambda}, \alpha, \sigma^2) = (2\pi)^{-n/2} |\boldsymbol{\Sigma}|^{-1/2} \exp \left( -\frac{(\mathbf{x} - \mathbf{Z}\boldsymbol{\lambda})' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \mathbf{Z}\boldsymbol{\lambda})}{2} \right)$$

Modello autoregressivo di ordine  $p$  (AR( $p$ )) XV

Possiamo sempre trovare una matrice  $\mathbf{A}$  tale per cui

$$\mathbf{A}\mathbf{A}' = \Sigma$$

e possiamo scrivere la verosimiglianza come

$$(2\pi)^{-2/2} |\mathbf{A}'\mathbf{A}|^{-1/2} \exp\left(-\frac{(\mathbf{x} - \mathbf{Z}\boldsymbol{\lambda})'(\mathbf{A}\mathbf{A}')^{-1}(\mathbf{x} - \mathbf{Z}\boldsymbol{\lambda})}{2}\right)$$

che è uguale a

$$(2\pi)^{-2/2} |\mathbf{A}'\mathbf{A}|^{-1/2} \exp\left(-\frac{(\mathbf{A}^{-1}\mathbf{x} - \mathbf{A}^{-1}\mathbf{Z}\boldsymbol{\lambda})'(\mathbf{A}^{-1}\mathbf{x} - \mathbf{A}^{-1}\mathbf{Z}\boldsymbol{\lambda})}{2}\right)$$

Se adesso definiamo  $\mathbf{X}^* = \mathbf{A}^{-1}\mathbf{X}$  e  $\mathbf{Z}^* = \mathbf{A}^{-1}\mathbf{Z}$  abbiamo che

$$\mathbf{X}^* \sim N(\mathbf{Z}^*\boldsymbol{\lambda}, \mathbf{I})$$

## Modello autoregressivo di ordine p (AR(p)) XVI

e quindi

$$x_i^* = \lambda_0 + \lambda_1 z_{i,1}^* + \cdots + \lambda_p z_{i,p}^* + \epsilon_i^*$$

con  $\epsilon_i^*$  iid da  $N(0, 1)$ . Abbiamo quindi che se conoscessimo  $\Sigma$  (che equivale a dire che conosciamo  $\alpha$  e  $\sigma$ ), possiamo stimare  $\lambda$  con lo stimatore dei minimi quadrati

$$\hat{\lambda} = ((\mathbf{Z}^*)' \mathbf{Z}^*)^{-1} (\mathbf{Z}^*)' \mathbf{x}^* = (\mathbf{Z}' (\mathbf{A}^{-1})' \mathbf{A}^{-1} \mathbf{Z})^{-1} \mathbf{Z}' (\mathbf{A}^{-1})' \mathbf{A}^{-1} \mathbf{x} =$$

$$(\mathbf{Z}' \Sigma^{-1} \mathbf{Z})^{-1} \mathbf{Z}' \Sigma^{-1} \mathbf{x} \quad (1)$$

che è chiamato lo stimatore GLS (generalized least squared). Tra i possibili metodi di stima, il più semplice e generale è un algoritmo iterativo, che partendo da valori iniziali per  $\alpha$  e  $\sigma$  calcola  $\hat{\Sigma}$ , da cui deriva lo stimatore di  $\hat{\lambda}$  in (1) e poi tenta di migliorarlo cambiando leggermente i valori di  $\alpha$  e  $\sigma$ , finchè si è raggiunto un massimo.

# Modello MA(1) I

## Modello Moving average

Il moving average al lag 1 (MA(1)) è scritto come

$$x_t = w_t + \beta w_{t-1} = (1 - \beta B)w_t$$

con  $w_t \sim N(0, \sigma^2)$  rumore bianco per ogni  $t$ . Il MA è un modello “speculare” all AR(). Possiamo facilmente calcolare medie e varianze che sono

$$E(X_t) = E(w_t + \beta w_{t-1}) = 0 + \beta 0 = 0$$

$$Var(X_t) = Var(w_t + \beta w_{t-1}) = \sigma^2 + \beta^2 \sigma^2 = \sigma^2(1 + \beta^2)$$

e funzione di autocovarianze

$$\gamma(k) = Cov(X_t, X_{t-k}) = Cov(w_t + \beta w_{t-1}, w_{t-k} + \beta w_{t-k-1})$$



## Modello MA(1) II

e quindi

$$\gamma(k) = \begin{cases} \sigma^2(1 + \beta^2) & \text{se } k = 0 \\ \beta\sigma^2 & \text{se } k = 1 \\ 0 & \text{altrimenti} \end{cases}$$

che è quindi stazionario. L'autocorrelazione è

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)} = \begin{cases} 1 & \text{se } k = 0 \\ \frac{\beta}{1+\beta^2} & \text{se } k = 1 \\ 0 & \text{altrimenti} \end{cases}$$

Visto che un MA(1) si può scrivere come

$$x_t = (1 + \beta B)w_t \Rightarrow (1 + \beta B)^{-1}x_t = w_t$$

## Modello MA(1) III

mostra come un MA(1), se  $|\beta| < 1$ , è un particolare  $AR(\infty)$  dato che (per gli stessi motivi del  $AR(p)$ )  $(1 + \beta B)^{-1}$  ha una rappresentazione in serie convergente

$$(1 + \beta B)^{-1} x_t = x_t + \sum_{j=1}^{\infty} c_j x_{t-j} = w_t$$

Quando è possibile invertire un MA per ottenere un  $AR(\infty)$ , si dice che il modello è invertibile e noi ci focalizzeremo solamente su questi modelli, perchè se non è invertibile non è neanche **identificabile**.

## Modello MA(1) IV

Facciamo una piccola digressione su cosa significa **identificabilità** di un modello. In statistica frequentista, noi stimiamo i parametri cercando quei valori che massimizzano la verosimiglianza. Ma cosa succede se più valori dei parametri la massimizzano? e se i valori sono infiniti? in questo caso noi non siamo in grado di distinguere tra i vari set di parametri che danno lo stesso valore (massimo) della verosimiglianza. Per esempio, se io assumo che

$$x_i \sim N(\lambda_1 - \lambda_2, 1), i = 1, \dots, n$$

e volessi stimare  $\lambda_1$  e  $\lambda_2$  e trovassi che la verosimiglianza si massimizza a  $\hat{\lambda}_1$  e  $\hat{\lambda}_2$ , avrei lo stesso valore di verosimiglianza anche per qualsiasi  $(\lambda_1^*, \lambda_2^*)$  tale che

$$\lambda_1^* = c + \hat{\lambda}_1, \quad \lambda_2^* = c + \hat{\lambda}_2$$

Se io sono interessato solo alla previsione, potrebbe non essere un problema, ma se i coefficienti vanno interpretati, allora diventa un problema da risolvere.

## Modello MA(1) V

Torniamo al processo e vediamo perchè non è identificabile.

Per capire perchè ricordate che il processo è completamente specificato da media e funzione di covarianza, e si può fare vedere che

$$x_t = w_t + \beta w_{t-1} \quad (1)$$

con  $w_t \sim N(0, \sigma^2)$ , e

$$x_t = w_t + \frac{1}{\beta} w_{t-1} \quad (2)$$

con  $w_t \stackrel{iid}{\sim} N(0, \beta^2 \sigma^2)$ , producono lo stesso processo. Questo perchè (1) e (2) hanno la stessa media, mentre la funzione di covarianza di (1) è

$$\gamma(k) = \begin{cases} \sigma^2(1 + \beta^2) & \text{se } k = 0 \\ \beta\sigma^2 & \text{se } k = 1 \\ 0 & \text{altrimenti} \end{cases}$$

## Modello MA(1) VI

come avevamo visto prima, e se definiamo  $\lambda = \frac{1}{\beta}$  e  $\beta^2 \sigma^2 = \tau^2$ , abbiamo che (2) è uguale a

$$x_t = w_t + \lambda w_{t-1}, \quad w_t \stackrel{iid}{\sim} N(0, \tau^2)$$

e allora la funzione di covarianza di (2) è

$$\gamma(k) = \begin{cases} \tau^2(1 + \lambda^2) & \text{se } k = 0 \\ \lambda \tau^2 & \text{se } k = 1 \\ 0 & \text{altrimenti} \end{cases}$$

che sostituendo ci da

$$\gamma(k) = \begin{cases} \beta^2 \sigma^2 (1 + \frac{1}{\beta^2}) & \text{se } k = 0 \\ \frac{1}{\beta} \beta^2 \sigma^2 & \text{se } k = 1 \\ 0 & \text{altrimenti} \end{cases}$$

## Modello MA(1) VII

che è uguale a

$$\gamma(k) = \begin{cases} \sigma^2(\beta^2 + 1) & \text{se } k = 0 \\ \beta\sigma^2 & \text{se } k = 1 \\ 0 & \text{altrimenti} \end{cases}$$

come in (1).

Quindi per indentificare il modello possiamo assumere che il parametro deve essere  $|\beta| \leq 1$ . Se è  $|\beta| < 1$  diciamo che è anche invertibile.

## Modello MA(1) VIII

Possiamo vedere un MA(1) in diverso modo. Abbiamo che

$$x_t = \beta w_{t-1} + w_t$$

Possiamo anche scrivere

$$x_{t-1} = \beta w_{t-2} + w_{t-1} \Rightarrow w_{t-1} = x_{t-1} - \beta w_{t-2}$$

Potremmo pensare di prendere  $w_{t-1}$  come funzione della serie temporale e sostituire il suo valore in  $x_t$ . Sebbene questo sia possibile, dobbiamo fare attenzione quando calcoliamo le caratteristiche della serie

$$x_t = \beta(x_{t-1} - \beta w_{t-2}) + w_t = \beta x_{t-1} - \beta^2 w_{t-2} + w_t$$

questo perchè, quando calcoliamo la varianza, abbiamo che

$$Var(x_t) = \beta^2 Var(x_{t-1}) + \beta^4 Var(w_{t-2}) + Var(w_t) -$$

## Modello MA(1) IX

$$2\beta^3 \text{Cov}(x_{t-1}, w_{t-2}) + 2\beta \text{Cov}(x_{t-1}, w_t) - 2\beta \text{Cov}(w_{t-2}, w_t)$$

Abbiamo

$$\text{Cov}(w_{t-2}, w_t) = \text{Cov}(x_{t-1}, w_t) = 0$$

ma

$$\text{Cov}(x_{t-1}, w_{t-2}) \neq 0$$

visto che nella sua definizione,  $x_{t-1}$ , che è

$$x_{t-1} = \beta w_{t-2} + w_{t-1}$$

dipende da  $w_{t-2}$ . Possiamo facilmente verificare che  $(x_{t-1}, w_{t-2})$  è una normale bivariate, con medie zero, con le varianze marginali di  $x_{t-1}$  e  $w_{t-2}$  pari a  $\sigma^2(1 + \beta^2)$  e  $\sigma^2$ , mentre la covarianza è

$$\beta\sigma^2$$



## Modello MA(1) X

Utilizzando le giuste covarianze, abbiamo che

$$\text{Var}(x_t) = \sigma^2(1 + \beta^2)$$

Possiamo continuare a sostituire e avere

$$\begin{aligned} x_t &= \beta x_{t-1} - \beta^2 w_{t-2} + w_t = \beta x_{t-1} - \beta^2 (x_{t-2} - \beta w_{t-3}) + w_t = \\ &\quad \beta x_{t-1} - \beta^2 x_{t-2} + \beta^3 w_{t-3} + w_t \end{aligned}$$

sostituiamo ancora e abbiamo

$$\begin{aligned} x_t &= \beta x_{t-1} - \beta^2 x_{t-2} + \beta^3 (x_{t-3} - \beta w_{t-4}) + w_t = \\ &\quad \beta x_{t-1} - \beta^2 x_{t-2} + \beta^3 x_{t-3} - \beta^4 w_{t-4} + w_t \end{aligned}$$

Abbiamo quindi che l'MA(1) originale si può scrivere come

$$x_t = w_t + \sum_{i=1}^{\infty} (-1)^{i+1} \beta^i x_{t-i}$$

che è un modello AR( $\infty$ )

## Modello MA(1) XI




Figure: Simulazione di un MA(1) con  $\beta = 0.3$

## Modello MA(1) XII

Code: Codice della figura

```
x = c()
beta_  = 0.3
sigma2 = 1.5
w = rnorm(100, 0, sigma2^0.5)
x1 = 0
for(i in 2:100)
{
  x[i] = w[i]+beta_*w[i-1]
}
x = x[-1]
par(mfrow=c(1,3))
par("mar"=c(5, 5, 4, 2))
plot(x, type="l", main="sim",
```

## Modello MA(1) XIII

```
      cex.main=3, cex.lab=3, cex.axis=3,  
      xlab="Time", ylab="Sim")  
acf(x, main="Acf", cex.main=3, cex.lab=3, cex.axis=3)  
pacf(x, main="p-Acf", cex.main=3, cex.lab=3, cex.axis=3)
```

## Modello MA(1) XIV




Figure: Simulazione di un MA(1) con  $\beta = 0.9$

## Modello MA(1) XV

Code: Codice della figura

```
x = c()
beta_  = 0.9
sigma2 = 1.5
w = rnorm(100, 0, sigma2^0.5)
x1 = 0
for(i in 2:100)
{
  x[i] = w[i]+beta_*w[i-1]
}
x = x[-1]
par(mfrow=c(1,3))
par("mar"=c(5, 5, 4, 2))
plot(x, type="l", main="sim",
```

## Modello MA(1) XVI

```
      cex.main=3, cex.lab=3, cex.axis=3,  
      xlab="Time", ylab="Sim")  
acf(x, main="Acf", cex.main=3, cex.lab=3, cex.axis=3)  
pacf(x, main="p-Acf", cex.main=3, cex.lab=3, cex.axis=3)
```

## Modello MA(1) XVII




Figure: Simulazione di un MA(1) con  $\beta = -0.3$



## Modello MA(1) XVIII

Code: Codice della figura

```
x = c()
beta_  = -0.3
sigma2 = 1.5
w = rnorm(100, 0, sigma2^0.5)
x1 = 0
for(i in 2:100)
{
  x[i] = w[i]+beta_*w[i-1]
}
x = x[-1]
par(mfrow=c(1,3))
par("mar"=c(5, 5, 4, 2))
plot(x, type="l", main="sim",
```

## Modello MA(1) XIX

```
cex.main=3, cex.lab=3, cex.axis=3,  
xlab="Time", ylab="Sim")  
acf(x, main="Acf", cex.main=3, cex.lab=3, cex.axis=3)  
pacf(x, main="p-Acf", cex.main=3, cex.lab=3, cex.axis=3)
```

Anche in questo caso, se vogliamo aggiungere un valore medio  $\mu$  basta scrivere

$$(x_t - \mu) = w_t + \beta w_{t-1} \Rightarrow x_t = \mu + w_t + \beta w_{t-1}$$

## Modello Moving Average di ordine $q$ (MA( $p$ )) I

### Modello Moving Average di ordine $q$ (MA( $q$ ))

Come con il modello autoregressivo, anche il moving average si può generalizzare introducendo più di un termine di ritardo

$$x_t = w_t + \beta_1 w_{t-1} + \beta_2 w_{t-2} + \beta_3 w_{t-3} + \cdots + \beta_q w_{t-q}$$

e definendo il backward shift polynomial

$$\phi_q(B) = (1 + \beta_1 B + \beta_2 B^2 + \cdots + \beta_q B^q)$$

abbiamo allora che

$$x_t = \phi_q(B)w_t.$$

Il modello MA( $q$ ) è identificabile se  $\phi_q(B)$  è invertibile, e  $\phi_q(B)$  è invertibile se e solo se tutte le radici hanno valore assoluto maggiore di 1.

## Modello Moving Average di ordine $q$ (MA( $p$ )) II

Come il caso precedente, è facile verificare che la media è 0 mentre la varianza è

$$Var(X_t) = \sigma^2 \sum_{j=0}^q \beta_j^2$$

assumendo  $\beta_0 = 1$ . La funzione di autocovarianza è

$$\gamma(k) = Cov(X_t, X_{t-k}) = Cov\left(\sum_{j=0}^q \beta_j w_{t-j}, \sum_{j=0}^q \beta_j w_{t-k-j}\right)$$

che è uguale a

$$\gamma(k) = \begin{cases} \sigma^2 \sum_{j=0}^q \beta_j^2 & \text{se } k = 0 \\ \sigma^2 \sum_{j=0}^{q-k} \beta_j \beta_{j+k} & \text{se } k = 1, \dots, q \\ 0 & \text{se } k > q \end{cases}$$

Modello Moving Average di ordine  $q$  (MA( $p$ )) III

che è quindi stazionario. L'autocorrelazione è

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)} = \begin{cases} 1 & \text{se } k = 0 \\ \frac{\sum_{j=0}^{q-k} \beta_j \beta_{j+k}}{\sum_{j=0}^q \beta_j^2} & \text{se } k = 1, \dots, q \\ 0 & \text{se } k > q \end{cases}$$

## Modello Moving Average di ordine q (MA(p)) IV




Figure: Simulazione di un MA(3) con  $\beta_1 = 0.8$ ,  $\beta_2 = -0.5$ ,  $\beta_3 = 0.3$

Modello Moving Average di ordine  $q$  (MA( $p$ )) V

Code: Codice della figura

```
x = c()
beta1 = 0.8
beta2 = -0.5
beta3 = 0.3
sigma2 = 1.5
w = rnorm(1000, 0, sigma2^0.5)
x1 = 0
for(i in 4:1000)
{
  x[i] = w[i]+beta1*w[i-1]+beta2*w[i-2]+beta3*w[i-3]
}
x = x[-c(1:500)]
par(mfrow=c(1,3))
```

## Modello Moving Average di ordine q (MA(p)) VI

```
par("mar"=c(5, 5, 4, 2))
plot(x, type="l", main="sim", cex.main=3,
     cex.lab=3, cex.axis=3, xlab="Time", ylab="Sim")
acf(x, main="Acf", cex.main=3, cex.lab=3, cex.axis=3)
pacf(x, main="p-Acf", cex.main=3, cex.lab=3, cex.axis=3)
```

Anche in questo caso si può aggiungere un livello diverso da zero con

$$(x_t - \mu) = w_t + \beta_1 w_{t-1} + \beta_2 w_{t-2} + \beta_3 w_{t-3} + \cdots + \beta_q w_{t-q} =$$

$$x_t = \mu + w_t + \beta_1 w_{t-1} + \beta_2 w_{t-2} + \beta_3 w_{t-3} + \cdots + \beta_q w_{t-q}$$

e come per il modello AR, la previsione deriva direttamente dalla distribuzione condizionate. Per esempio per un MA(1) abbiamo

$$x_t = w_t + \beta w_{t-1}$$



## Modello Moving Average di ordine q (MA(p)) VII

e la serie al tempo  $t + 1$  è

$$x_{t+1} = w_{t+1} + \beta w_t$$

Vediamo le connessioni con il modello AR(1). Il modello AR(1) è

$$(1 - \alpha B)x_t = w_t \Rightarrow x_t = (1 - \alpha B)^{-1}w_t = \sum_{j=0}^{\infty} \alpha^j w_{t-j}$$

che quindi, può essere scritto come un  $MA(\infty)$ . Questo è vero anche per un generico  $AR(p)$ .

Un MA(q) può sempre essere visto come un  $AR(\infty)$ , e quindi non è mai markoviano'

# ARMA model I

## Modello ARMA(p,q)

I modelli AR e MA sono tutto ciò che ci serve per modellare processi gaussiani stazionari visto che

### Teorema di rappresentazione di Wold

Qualsiasi processo stocastico  $\{X_t\}_{t \in \mathbb{Z}}$  debolmente stazionario di ordine 2 a media nulla può essere espresso come

$$X_t = \sum_{j=0}^{\infty} b_j w_t$$

con  $w_t$  rumore bianco (media zero e varianza finita, non per forza Gaussiano), assumendo

$$\sum_{j=0}^{\infty} |b_j|^2 < \infty$$

Quindi un processo gaussiano si può sempre rappresentare con un  $MA(\infty)$ . La serie non deve per forza essere infinita.

## ARMA model II

Possiamo mettere insieme il modello AR(p) e MA(q) in un unico modello, chiamato ARMA(p,q) nel seguente modo

$$x_t = \alpha_1 x_{t-1} + \dots \alpha_p x_{t-p} + w_t + \beta_1 w_{t-1} + \dots \beta_q w_{t-q}$$

In questo caso  $x_t$  segue un modello ARMA(p,q).

**Attenzione:** Nel modello ARMA, e in tutti i seguenti, visto che sono formati da componenti AR e MA, previsione, e valori medi diversi da zero si calcolano/aggiungono come si è fatto per i primi due modelli

Il modello si può scrivere in forma più concisa usando i polinomi backshift

$$\theta_p(B)x_t = \phi_q(B)w_t$$

Notate che

## ARMA model III

- Il processo è stazionario se le radici di  $\theta_p(B)$  sono maggiori di 1 in valore assoluto
- Il processo è invertibile se le radici di  $\phi_q(B)$  sono maggiori di 1 in valore assoluto
- ARMA(p,0) è un AR(p)
- ARMA(0,q) è un MA(q)
- In generale, la stima di un ARMA richiede meno parametri di quelle che sarebbero necessari per un AR() o un MA(), visto che se  $\theta_p(B)$  e  $\phi_q(B)$  hanno un fattore in comune, e il modello è stazionario, allora si possono semplificare. Per esempio, se

$$\left(1 - \frac{1}{2}B\right) \left(1 - \frac{1}{3}B\right) x_t = \left(1 - \frac{1}{2}B\right) w_t$$

può essere semplificato in

$$\left(1 - \frac{1}{3}B\right) x_t = w_t$$

## ARMA model IV

Anche in questo caso trovare le proprietà (autocorrelazione e autocovarianza) per un generico ARMA(p,q) è complesso, ma possiamo farlo nel caso ARMA(1,1). Ipotizziamo di avere

$$x_t = \alpha x_{t-1} + w_t + \beta w_{t-1} \Rightarrow (1 - \alpha B)x_t = (1 + \beta B)w_t \Rightarrow x_t = (1 - \alpha B)^{-1}(1 + \beta B)w_t$$

che può essere anche scritto come

$$x_t = \left( \sum_{j=0}^{\infty} \alpha^j B^j \right) (1 + \beta B)w_t = \left( 1 + \alpha \sum_{j=0}^{\infty} \alpha^j B^{j+1} + \beta \sum_{j=0}^{\infty} \alpha^j B^{j+1} \right) w_t =$$

$$w_t + (\alpha + \beta) \sum_{j=0}^{\infty} \alpha^j B^{j+1} w_t = w_t + (\alpha + \beta) \sum_{j=1}^{\infty} \alpha^{j-1} w_{t-j}$$

L'equazione di sopra mostra che  $E(x_t) = 0$  e

$$Var(X_t) = \sigma^2 + \sigma^2(\alpha + \beta)^2 \frac{1}{1 - \alpha^2}$$

## ARMA model V

e possiamo calcolare facilmente

$$\gamma(k) = \text{Cov}(X_t, X_{t-k}) = \text{Cov}(w_t + (\alpha + \beta) \sum_{j=1}^{\infty} \alpha^{j-1} w_{t-j}, w_{t-k} + (\alpha + \beta) \sum_{j=1}^{\infty} \alpha^{j-1} w_{t-k-j})$$

$$\gamma(k) = (\alpha + \beta) \alpha^{k-1} \sigma^2 + (\alpha + \beta)^2 \sigma^2 \alpha^k \sum_{j=1}^{\infty} \alpha^{2j-2} =$$

$$(\alpha + \beta) \alpha^{k-1} \sigma^2 + (\alpha + \beta)^2 \sigma^2 \alpha^k \frac{1}{1 - \alpha^2}$$

e si può dimostrare che

$$\rho(k) = \frac{\alpha^{k-1} (\alpha + \beta) (1 + \alpha\beta)}{1 + \alpha\beta + \beta^2} = \alpha \rho(k-1)$$

# I modelli integrati I

## Integreted model

Prendiamo un semplice caso di un modello che ha senso e potrebbe essere utile per analizzare un fenomeno, ma non è un ARMA:

$$x_t = x_{t-1} + w_t$$

Questa assomiglia a un AR(1), con parametro  $\alpha = 1$ , che abbiamo detto essere quindi non stazionario, ma è utile nei casi pratici perchè ci dice che la posizione al tempo  $t$  è una traslazione basata su  $w_t$  di dove eravamo al tempo precedente. Potremmo prendere le differenze prime

$$x_t^* = x_t - x_{t-1} = w_t$$

e il modello basato su  $x_t^*$  diventa un rumore bianco. Questa è la definizione base di un serie integrata di ordine 1 (I(1)).

In generale

## I modelli integrati II

### Modello Integrato I(d)

Una serie si dice integrata di ordine  $d$  se la differenziazioni di ordine  $d$  produce un rumore bianco:

$$(1 - B)^d x_t = (1 - B)(1 - B) \dots (1 - B)x_t = w_t$$



## I modelli integrati III

Le serie integrate possono essere utili ma le differenze (di diversi ordini) si possono usare anche per passare da modelli non stazionari a modelli ARMA. Prendiamo un semplice esempio in cui

$$x_t = a + bt + w_t$$

non è stazionario. Se prendessimo le differenze prime

$$x_t - x_{t-1} = a + bt + w_t - a - b(t-1) - w_{t-1} = b + w_t - w_{t-1}$$

la serie è stazionaria. Fate attenzione che  $x_t - x_{t-1} = (1 - B)x_t$  è un MA(1), con parametro  $\beta = -1$  e quindi non invertibile, con valore medio differente da zero.

Scriviamo

$$(1 - B)x_t = b + (1 - B)w_t$$

## I modelli integrati IV

Se vogliamo togliere il valor medio, e renderlo zero. possiamo differenziare un'altra volta

$$(1 - B)(1 - B)x_t = (1 - B)^2 x_t = b + (1 - B)w_t - b - (1 - B)w_{t-1} =$$

$$(1 - B)(w_t - w_{t-1}) = (1 - B)(1 - B)w_t = (1 - B)^2 w_t$$

che è anche uguale a

$$(1 - B)(1 - B)x_t = w_t - 2Bw_t + B^2 w_t = w_t - 2w_{t-1} + w_{t-2}$$

che è un MA(2). Vediamo sotto delle simulazioni di  $x_t$  e delle differenze prime e seconde

## I modelli integrati V




Figure: Simulazione di un rumore bianco con trend

# I modelli integrati VI

Code: Codice della figura

```
set.seed(500)
n = 500
a = 1
b = 5
x = rnorm(n, a+b*1:n, 2.5^0.5)
par(mfrow=c(1,3))
par("mar"=c(5, 5, 4, 2))
plot(x, type="l", main="sim", cex.main=3,
      cex.lab=3, cex.axis=3, xlab="Time", ylab="Sim")
acf(x, main="Acf", cex.main=3, cex.lab=3, cex.axis=3)
pacf(x, main="p-Acf", cex.main=3, cex.lab=3, cex.axis=3)
```

## I modelli integrati VII




Figure: Simulazione di un rumore bianco con trend - differenze prime

# I modelli integrati VIII

Code: Codice della figura

```
set.seed(500)
n = 500
a = 1
b = 5
x = rnorm(n, a+b*1:n, 2.5^0.5)
par(mfrow=c(1,3))
par("mar"=c(5, 5, 4, 2))
plot(diff(x), type="l", main="sim", cex.main=3,
      cex.lab=3, cex.axis=3, xlab="Time", ylab="Sim")
acf(diff(x), main="Acf", cex.main=3, cex.lab=3, cex.axis=3)
pacf(diff(x), main="p-Acf", cex.main=3, cex.lab=3, cex.axis=3)
```

## I modelli integrati IX




Figure: Simulazione di un rumore bianco con trend - differenze seconde

# I modelli integrati X

Code: Codice della figura

```
set.seed(500)
n = 500
a = 1
b = 5
x = rnorm(n,a+b*1:n,2.5^0.5)
par(mfrow=c(1,3))
par("mar"=c(5, 5, 4, 2))
plot(diff(diff(x)), type="l", main="sim", cex.main=3,
      cex.lab=3, cex.axis=3, xlab="Time", ylab="Sim")
acf(diff(diff(x)), main="Acf", cex.main=3, cex.lab=3, cex.axis=3, xlab="Time", ylab="Acf")
pacf(diff(diff(x)), main="p-Acf", cex.main=3, cex.lab=3, cex.axis=3, xlab="Time", ylab="p-Acf")
```



## I modelli integrati XI

Si può dimostrare che un ARIMA

- per eliminare un trend deterministico di ordine  $d$  (del tipo  $a + bt + ct^2 + \dots ht^d$ ), servono  $d$  differenziazioni
- per eliminare un trend stocastico di ordine  $d$  (del tipo  $x_{t-1} + x_{t-2} + \dots, x_{t-d}$ ), servono  $d$  differenziazioni.
- se si differenzia a livello  $d$  per eliminare un trend deterministico, si introduce una componente stagionale di ordine  $d$  nella parte MA

Un modello che integrato  $d$  volte produce un ARMA si dice ARIMA di parametri  $(p,d,q)$  si può scrivere come

$$\theta_p(B)(1 - B)^d x_t = \phi_q(B)w_t$$

**Attenzione:** prima di integra, e poi il modello è ARMA sulle differenze.

Esempi:

## I modelli integrati XII

Il modello

$$x_t = x_{t-1} + w_t + \beta w_{t-1}$$

si può scrivere come

$$x_t - x_{t-1} = (1 - B)x_t = w_t + \beta w_{t-1}$$

che è un ARMA(0,1,1), che si scrive anche come IMA(1,1), cioè integrated MA.

Un esempio di simulazione è mostrata sotto per il  $x_t$  (prima figura) e per  $(1 - B)x_t$  (seconda figura)

## I modelli integrati XIII




Figure: Simulazione dell'ARIMA(0,1,1) dell'esempio precedente

## I modelli integrati XIV

Code: Codice della figura

```
set.seed(100)
x = c()
beta1      = 0.5
sigma2     = 1.5
w = rnorm(1000, 0, sigma2^0.5)
x[1:4] = 0
for(i in 4:600)
{
  x[i] = x[i-1]+w[i]+beta1*w[i-1]
}
x = x[-c(1:100)]
par(mfrow=c(1,3))
par("mar"=c(5, 5, 4, 2))
```

## I modelli integrati XV

```
plot(x, type="l", main="sim", cex.main=3,  
     cex.lab=3, cex.axis=3, xlab="Time", ylab="Sim")  
acf(x, main="Acf", cex.main=3, cex.lab=3, cex.axis=3)  
pacf(x, main="p-Acf", cex.main=3, cex.lab=3, cex.axis=3)
```

## I modelli integrati XVI




Figure: Simulazione dell'ARIMA(0,1,1) dell'esempio precedente

## I modelli integrati XVII

Code: Codice della figura

```
set.seed(100)
x = c()
beta1      = 0.5
sigma2     = 1.5
w = rnorm(1000, 0, sigma2^0.5)
x[1:4] = 0
for(i in 4:600)
{
  x[i] = x[i-1]+w[i]+beta1*w[i-1]
}
x = x[-c(1:100)]
par(mfrow=c(1,3))
par("mar"=c(5, 5, 4, 2))
```

## I modelli integrati XVIII

```
plot(diff(x), type="l", main="sim", cex.main=3,  
      cex.lab=3, cex.axis=3, xlab="Time", ylab="Sim")  
acf(diff(x), main="Acf", cex.main=3, cex.lab=3, cex.axis=3)  
pacf(diff(x), main="p-Acf", cex.main=3, cex.lab=3, cex.axis=3)
```

Un altro esempio è il modello

$$x_t = \alpha x_{t-1} + x_{t-1} - \alpha x_{t-2} + w_t$$

si può scrivere come

$$(1 - B)x_t = x_t - x_{t-1} = \alpha(x_{t-1} - x_{t-2}) + w_t = \alpha(1 - B)x_{t-1} + w_t$$

è un ARIMA(1,1,0), o IAR(1,1). Un esempio di simulazione è mostrata sotto per il  $x_t$  (prima figura) e per  $(1 - B)x_t$  (seconda figura)



## I modelli integrati XIX




Figure: Simulazione dell'ARIMA(1,1,0) dell'esempio precedente

# I modelli integrati XX

Code: Codice della figura

```
set.seed(100)
x = c()
alpha      = 0.5
sigma2     = 1.5
w = rnorm(1000, 0, sigma2^0.5)
x[1:4] = 0
for(i in 4:600)
{
  x[i] = alpha*x[i-1]+x[i-1]-alpha*x[i-2]+w[i]
}
x = x[-c(1:100)]
par(mfrow=c(1,3))
par("mar"=c(5, 5, 4, 2))
```

## I modelli integrati XXI

```
plot(x, type="l", main="sim", cex.main=3,  
      cex.lab=3, cex.axis=3, xlab="Time", ylab="Sim")  
acf(x, main="Acf", cex.main=3, cex.lab=3, cex.axis=3)  
pacf(x, main="p-Acf", cex.main=3, cex.lab=3, cex.axis=3)
```

## I modelli integrati XXII




Figure: Simulazione dell'ARIMA(1,1,0) dell'esempio precedente

## I modelli integrati XXIII

Code: Codice della figura

```
set.seed(100)
x = c()
alpha      = 0.5
sigma2     = 1.5
w = rnorm(1000, 0, sigma2^0.5)
x[1:4] = 0
for(i in 4:600)
{
  x[i] = alpha*x[i-1]+x[i-1]-alpha*x[i-2]+w[i]
}
x = x[-c(1:100)]
par(mfrow=c(1,3))
par("mar"=c(5, 5, 4, 2))
```

## I modelli integrati XXIV

```
plot(diff(x), type="l", main="sim", cex.main=3,  
      cex.lab=3, cex.axis=3, xlab="Time", ylab="Sim")  
acf(diff(x), main="Acf", cex.main=3, cex.lab=3, cex.axis=3)  
pacf(diff(x), main="p-Acf", cex.main=3, cex.lab=3, cex.axis=3)
```

# Modello ARIMA stagionale I

## Stagionalità

La stagionalità è una caratteristica spesso presente nelle serie temporale, sia in forma di modello integrato (trend stocatici e deterministici) che di AR o MA. Per esempio, immaginiamo che  $x_t$  sia la temperatura e  $t$  rappresenti il mese/anno. Potremmo avere

- 1)  $x_t = a_{t \bmod 12} + w_t$ , un rumore bianco con un valore medio che cambia ongni mese e si ripete ogni 12
- 2)  $x_t = x_{t-12} + w_t$ , un modello integrato in cui la temperatura in un mese è una variazione dello stesso mese nell'anno precedente
- 3)  $x_t = \alpha_1 x_{t-12} + \alpha_2 x_{t-24} + w_t$ , un AR(2) ma su base stagionale
- 4)  $x_t = w_t + \beta_1 w_{t-12} + \beta_2 w_{t-24}$ , un MA(2) ma su base stagionale

## Modello ARIMA stagionale II

Questi non sono gli unici casi, ma fanno capire le modellizzazioni. Come per i modelli ARIMA, il punto 1 e 2 si possono risolvere differenziando, ma con un distanza temporale di 12

$$(1 - B^{12})x_t = (1 - B^{12})w_t$$

e

$$(1 - B^{12})x_t = w_t$$

Il punto 3 si può scrivere come un AR(2) ma con polinomio autoregressivo a potenza 12

$$(1 - \alpha_1 B^{12} - \alpha_2 B^{24})x_t = w_t$$

Il punto 4 si può scrivere come un MA(2) ma con polinomio a media mobile a potenza 12

$$x_t = (1 + \beta_1 B^{12} - \beta_2 B^{24})w_t$$



## Modello ARIMA stagionale III

I modello sopra potrebbero essere parti di modelli con componenti ARIMA standard, per esempio

$$x_t = x_{t-1} + \alpha x_{t-12} - \alpha x_{t-13} + w_t$$

si può scrivere come

$$(1 - B)x_t = \alpha(1 - B)x_{12} + w_t \Rightarrow (1 - \alpha B^{12})(1 - B)x_t = w_t$$

Se definiamo

$$\Theta_P(B^s) = (1 - \alpha_1^* B^{1s} - \alpha_2^* B^{2s} - \dots - \alpha_P^* B^{Ps})$$

dove  $s$  rappresenta la stagionalità, e

$$\Phi_Q(B^s) = (1 + \beta_1^* B^{1s} + \beta_2^* B^{2s} + \dots + \beta_P^* B^{Ps})$$

un modello che si può scrivere come

$$\Theta_P(B^s)\theta_p(B)(1 - B^s)^D(1 - B)^d x_t = \Phi_Q(B^s)\phi_q(B)w_t$$

## Modello ARIMA stagionale IV

è un arima stagionale  $ARIMA(p, d, q)(P, D, Q)_s$

Naturalmente un effetto stagionale di periodo  $s$  introduce correlazione tra osservazioni a distanze  $s$ . L'effetto stagionale può essere facilmente visto dal correlogramma.

Esempi classici di effetti stagionali deterministici sono

- un classico effetto “fattore”, simile ai modelli regressivi, dove tutti i punti temporali  $i + s$ , con  $s \in \mathbb{Z}$ , hanno lo stesso valore del fattore:


$$x_t = a_{t \bmod s} + w_t$$

- una funzione ciclica, del tipo seno/coseno

$$x_t = \psi \sin(2\pi\lambda t + \phi) + w_t$$

dove  $(\psi, \lambda, \phi)$  sono parametri.

# Modello ARIMA stagionale V



**Figure:** Simulazione di un AR(1) con effetto stagionale di lunghezza 12

## Modello ARIMA stagionale VI

Code: Codice della figura

```
x = c()
alpha    = 0.8
sigma2    = 0.5
x[1] = rnorm(1,0,(sigma2/(1-alpha^2))^0.5)
beta = rep(c(0,1,2,3,2,1,0,-1,-2,-3,-2,-1), times=10)
for(i in 2:120)
{
  x[i] = rnorm(1,alpha*x[i-1],sigma2^0.5)
}
y = x+beta
par(mfrow=c(1,3))
par("mar"=c(5, 5, 4, 2))
plot(y, type="l", main="sim", cex.main=3,
```

## Modello ARIMA stagionale VII

```
      cex.lab=3, cex.axis=3, xlab="Time", ylab="Sim")  
acf(y, main="Acf", cex.main=3, cex.lab=3, cex.axis=3)  
pacf(y, main="p-Acf", cex.main=3, cex.lab=3, cex.axis=3)
```

